

計量時系列分析

第8回

2026年6月16日(火)

単位根過程

- 定常過程の性質
 1. トレンドがない × GDP, 物価
 2. 平均回帰性 × 株価, 為替
- 原系列が非定常過程であり, 差分系列が定常過程であるとき, 原系列の過程を単位根過程(unit root process) という.
- $d-1$ 階差分を取った系列は非定常であるが, d 回差分を取った系列が定常の過程を, d 次和分過程または $I(d)$ 過程という.
- d 回差分を取った系列が定常かつ反転可能な $ARMA(p,q)$ 過程に従うとき, $ARIMA(p,d,q)$ という.
- 過程が

$$y_t = \delta + y_{t-1} + u_t, \quad u_t \sim \text{iid}(0, \sigma^2)$$

に従うとき, y_t はランダムウォークと呼ばれる(代表的な単位根).

単位根過程とトレンド定常過程

- 単位根過程は線形トレンドを記述できる

$$y_t = \delta t + v_t$$

- 確率的トレンド v_t
- ドリフト率 δ

- 線形トレンドを記述できるもう一つの過程：
 x_t を定常過程として

$$y_t = \delta t + x_t$$

に従う y_t はトレンド定常過程と呼ばれる.

- 両者の違い

- y_t と x_t の平均を0と仮定
- トレンド定常過程の場合

$$E(y_t - \delta t)^2 = \text{Var}(x_t)$$

➡ 線形トレンドとの差が一定の範囲に収まる

- ランダムウォークの場合

$$E(y_t - \delta t)^2 = \text{Var}(v_t) = \sigma^2 t$$

➡ 線形トレンドとの差が(平均的に)限りなく大きくなっていく

単位根過程の予測

- 原則は同じ
- 定常過程と比較するため, $\delta=0$ とする.
- 定常過程と同様に

$$y_{t+h} = y_t + u_{t+h} + u_{t+h-1} + u_{t+h-2} + \cdots + u_{t+1}$$

したがって h 期先最適予測は

$$\hat{y}_{t+h|t} = y_t$$

- 予測が y_t にしか依存しないことは定常過程と同じ
- そのウェイトが異なる → 平均回帰的ではない

- ランダムウォークの予測のMSE

$$E(u_{t+h} + u_{t+h-1} + u_{t+h-2} + \cdots + u_{t+1})^2 = \sigma^2 h$$

- 限りなく大きくなっていく

- 定常の場合, 過程の分散に収束した

- イメージ

- 株価の予測

- どんな将来でも現在を起点に予測するであろう
 - 遠い将来ほど予測は難しい

- ➡ 単位根過程

- 株式収益率の予測

- 今の収益率は長期的な予測に影響を及ぼさない
 - 遠い将来でも予測はそれほど変わらない

- ➡ 定常過程

単位根検定

- 単位根過程とトレンド定常過程は大きく異なる
⇒検定が必要
- Dickey-Fuller (DF) 検定
- 拡張 DF (ADF) 検定
- Phillips-Perron (PP) 検定

見せかけの回帰

- 2つの独立なランダムウォークを考える

$$x_t = x_{t-1} + v_t$$

$$y_t = y_{t-1} + w_t$$

- 回帰モデルに当てはめてみる

$$y_t = \alpha + \beta x_t + \epsilon_t$$

- t 検定を行うと・・・
 1. $H_0: \alpha = \beta = 0$ が(ほぼ確実に)棄却される！
 2. R^2 が1に収束する！

- 定義：単位根過程 y_t を定数と y_t と関係のない単位根過程 x_t に回帰すると、 x_t と y_t の間に有意な関係があり、回帰の説明力が高いように見える現象を**見せかけの回帰 (spurious regression)** という。

- 解決法

- 非説明変数のラグ変数を回帰に含める

$$y_t = \alpha + \beta_1 x_t + \beta_2 x_{t-1} + \beta_3 y_{t-1} + \epsilon_t$$

- 差分を取り定常過程にしてから解析する

$$\Delta y_t = \alpha + \beta \Delta x_t + \epsilon_t$$

共和分

- 単位根過程の差分をとる問題点：共和分するとき
 - 元の回帰が見せかけの回帰 (spurious regression) ではない
 - 共和分の関係を考慮した特別なモデルが必要
 - 分析の前には、
 - 実際に単位根かどうか
 - 見せかけの回帰かどうかを慎重に判断する必要
 - 見せかけの回帰の判別法
 - $x, y \sim I(1)$ のとき, 回帰の誤差項について
 - $\varepsilon_t \sim I(1) \Rightarrow$ 「見せかけの回帰」
 - $\varepsilon_t \sim I(0) \Rightarrow$ 「共和分の関係」
- ➡ ε_t の単位根検定を行う (Engle-Granger 共和分検定)

- 和分過程の線形和の性質
 - 定 常 + 定 常 $\rightarrow$ 定 常
 - 単位根 + 定 常 $\rightarrow$ 単位根
 - 単位根 + 単位根 $\rightarrow$ どちらにもなる

定義(共和分)

- $x, y \sim I(1)$ とする。
- $ax_t + by_t \sim I(0)$ となるような a, b が存在するとき、 x と y の間には **共和分(cointegration)** の関係がある／**共和分している(cointegrated)** という。
- $(a, b)'$ を **共和分ベクトル (cointegrated vector)** という。
- 共和分は一意に定まらない
 - $(a, b)'$ が共和分ベクトルのとき $(2a, 2b)'$ も共和分ベクトル
 - $a=1$ や $\sqrt{a^2 + b^2} = 1$ と基準化する
 - n 変数では最大 $n-1$ 個の共和分関係がある (**共和分ランク**)

- 共和分の経済学的な意味
 - x, y は単位根過程
 - 平均回帰的でなく、予測MSE発散
 - 共和分ならば $z_t = y_t - ax_t \sim I(0)$ となるような a が存在
 - z は平均回帰的であり、予測精度は一定
 - 長期的には $y_t = ax_t + b (= E(z_t))$ という均衡関係が成立
 - 経済・ファイナンス理論に多く、非常に有用
- 例
 - ケインズ型消費関数 $C_t = \alpha + \beta Y_t$
 - 購買力平価(PPP; purchasing power parity)仮説
 - フィッシャー効果

季節調整入門

- 経済データには季節性または季節変動と呼ばれる, 1年を周期とする変動が存在する
- GDP, 家計支出, 鉱工業生産指数 etc
- 季節性を生み出す要因
 - 天候・・・寒暖
 - 暦・・・月による日数や休日数の違い
 - 社会的慣習・・・中元・歳暮, クリスマス
 - 予測・・・クリスマス商戦

経済統計データの変動要因と季節性

- 経済統計データの原因系列 O を分解する
 - 傾向変動 T
 - 循環変動 C
 - 季節変動 S
 - 不規則変動 I
- 乗法型／加法型分解モデル
 - 乗法型が一般的
 - 乗法型の対数を取ると加法型になる

- 傾向変動 (Trend)
 - 趨勢的な長期変動
 - 数年から20年程度, 傾向が変化しない
 - 線形, 2次曲線, 指数曲線などで表現される
 - 人口構造や技術進歩によってもたらされる
- 循環変動 (Cycle)
 - 周期的な変動のうち, 周期が1年を超える中期的な変動
 - 周期関数(三角関数など)の組み合わせで表現される
 - 代表例: 景気循環(キチンの波、ジュグラーの波、クズネッツの波、コンドラチェフの波)

- 季節変動 (Seasonal)
 - 1年を周期とする変動
 - 変動の幅の大きさは安定的
 - 1年間の変動の和が0(加法型)／積が1(乗法型)
 - 1年前の同期の変動は同じとみなす場合がある
- 不規則変動 (Irregular)
 - 周期性を持たないランダムな変動
 - 傾向・循環・季節を除去した残りの変動
 - 災害, 値上げ, 政策変更, 統計誤差

季節変動を分離する必要性

- 政策は中期的な変動（GDP, 雇用, 物価など）のコントロールを目的することが多い → 季節変動を除去
- 短期・突発的な変動（不規則変動）に対する評価も重要である → 不規則変動と季節性の分離
- より良い予測ができる
- 季節性そのものを知りたい
 - 季節性のある製品の需要予測
 - 季節性を考慮した政策決定

季節調整法

- 簡便な方法
 - 前年比
 - 単純な移動平均
 - 移動平均法
- 官庁統計等の実務で用いられる方法
 - X-11・・・米国センサス局. 移動平均をベースにした方法
 - X-12-ARIMA・・・米国センサス局開発, 日欧でも使用
 - TRAMO-SEATS・・・スペイン銀行開発, 欧州で使用
 - X-13ARIMA-SEATS・・・X-12にSEATSの機能を追加

参考: 野木森 稔「季節調整法に関する最近の動向: X-12-ARIMA からX-13ARIMA-SEATS へ」

前年比

- 季節性は毎年同じパターン→1年前のデータにも同じ季節性が含まれるはず
 - 乗法型モデルを例に
 - 1年前と同じとすると

- 前年比の問題点
 - 1年前に大きな変動があると、当年に何もなくても大きく変動する「前年のウラ」
 - 短期的な増減、足元の動きを議論しづらい
 - 加法型には不適切
- 前年比の前期差
 - 短期的な増減の議論ができる
 - 「前年のウラ」の問題は残る

単純な移動平均


- 季節性は毎年同じパターン→1年前のデータにも同じ季節性が含まれるはず
 - 加法型モデル

- 移動平均の問題点

- 季節変動だけでなく不規則変動も除去されてしまう
 - 短期的な経済動向の分析には不規則変動も重要
- 1年の時点数が偶数の場合, 代表する時点が整数にならない
 - 移動平均を2段階行う「中心化」で解決
- データの最初と最後の半年分が算出できない(データ端の問題)
 - 足元の経済動向が分析できない

➡ 季節調整法は, 上記の問題を解消または緩和しながら, 季節性を取り除く方法

図 1-13 家計支出の季節調整値と原系列



(出典) 総務省「家計調査」。


出典: 有田帝馬『入門 季節調整』

「移動平均法」

- 移動平均は、特に短期的な変動に関心がある場合に実用上の問題がある
- 中心化移動平均
 - 不規則変動, 季節変動は除去されている
 - T, C は1年単位では穏やかなので, t 時点で代表させる
 - 季節・不規則変動の抽出

- タテの移動平均
 - 不規則変動は除去されるが、季節性は残る
 - 各期を代表する季節変動を準備できるため、データ端の問題も解消する
- (移動平均法による) 季節調整済系列

図2-10 移動平均法と X-11（公表値）の比較



(出典) 総務省「家計調査」をもとに作成。

X-11 の概略

- 移動平均をベースとする季節調整法
- 現在主流のX-12-ARIMA, 最新の X-13ARIMA-SEATS の主要部分を構成
- 通常を中心化移動平均に加え, ウェイトに工夫が施された加重移動平均(ヘンダーソン移動平均)を用いる. データ端の問題に対しても移動平均のウェイトを工夫(代理ヘンダーソン移動平均)
- 加重移動平均の項数の自動設定
- 異常値の自動処理
- 複数回の移動平均により, 季節調整の精度を向上

市場リスクの計測: リスク指標

- バリュー・アット・リスク (VaR: Value at Risk)

$$VaR_p[X] = -\inf\{x \mid P[X \leq x] > 1-p\}, \quad 0 < p < 1$$

- 期待ショートフォール (ES: Expected Shortfall)


$$ES_p[X] = E[-X \mid -X \geq VaR_p[X]], \quad 0 < p < 1$$

➡ 推定の方法

- ① 分散を推定し, その分散を持つ何らかの分布 (正規分布, t-分布 etc.) の分位点を求める
- ② 分布を直接推定する


etc...

Loss of an asset (or portfolio)




ボラティリティ (Volatility)

- 金融資産価格, またはその利益率の変動の大きさ
- ボラティリティが大きい→資産価格の変動が大きい→大きな損失／利益が出やすい
- 標準偏差または分散(2次モーメント)
- σ または σ^2 で表す
- 金融経済学における「リスク」の指標



ボラティリティ小



ボラティリティ大

- 期待値(期待収益率)の予測は難しいが(効率的市場仮説), ボラティリティは予測できる

VaRのバックテスト

- 真のVaRは分からない
- 過去のデータを用いてVaRを超過した回数を数える
 - 99%VaRであれば、平均的に100回に1回超過するはず
 - ただし、偶然の要素もある
- 目安(BISの場合)
 - 1年間(250営業日)で99%VaRの超過回数が...
 - グリーン・ゾーン: 4回以内
 - イエロー・ゾーン: 5回以上9回以内
 - レッド・ゾーン : 10回以上 →規制当局から改善要求

日次ボラティリティの推定

- 多くの金融商品では、収益率が大きく変動する時期が集中して現れる(ボラティリティ・クラスタリング)
 - ボラティリティは無相関ではない
 - ボラティリティの自己相関をモデル化することで予測ができる
 - VaR等のリスク指標の計算に役立つ
 - その他, 収益率の区間予測, ポートフォリオの選択, オプションの価格付けなどに用いられる

方法

1. 日次データを使う
 - ARCH, GARCH モデル
2. 高頻度データを使う
 - 1日の全取引データ
 - その日のボラティリティを直接計算する

GARCH

- 収益率を次のようにモデル化する

$$y_t = \mu_t + u_t = \mu_t + \sqrt{h_t}v_t, \quad v_t \sim \text{iid}N(0, 1)$$

ここで

$$\mu_t = E[y_t | \Omega_{t-1}]$$

- h_t のモデル化の2つのタイプ

- GARCH モデル

h_t は $t-1$ 時点までの情報集合 Ω_{t-1} の確定的な関数

- 確率的ボラティリティ (SV; stochastic volatility) モデル

h_t は Ω_{t-1} に含まれない確率的ショックを含む

GARCH は ARCH (autoregressive conditional heteroskedasticity) を一般化させたもの

$$y_t = \mu_t + u_t = \mu_t + \sqrt{h_t}v_t, \quad v_t \sim \text{iid}N(0, 1)$$

- ARCH (m)

$$h_t = \omega + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \cdots + \alpha_m u_{t-m}^2$$

- GARCH (r, m)

$$h_t = \omega + \beta_1 h_{t-1} + \cdots + \beta_r h_{t-r} + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \cdots + \alpha_m u_{t-m}^2$$

- 金融時系列のボラティリティは、長期にわたって大きな正の自己相関を持つ。そのようなデータに対して ARCH は次数が大きくなる
- GARCH はより少ないパラメータで記述できる

- 他にも, GJRモデル, EGARCH モデルなどがある.

$$y_t = \mu_t + u_t = \mu_t + \sqrt{h_t}v_t, \quad v_t \sim \text{iid}N(0, 1)$$

- GJR (1,1)

$$h_t = \omega + \beta h_{t-1} + \alpha u_{t-1}^2 + \gamma u_{t-1}^2 \cdot I_{t-1}\{u_{t-1} < 0\}$$

- Glosten, Jagannathan and Runkle (1993)
- 負のショックのほうが大きい影響を持つレバレッジ効果を捉えている

- EGARCH (1, 1)

$$\log h_t = \omega + \beta \log h_t + \gamma v_{t-1} + \delta(|v_{t-1}| - E|v_{t-1}|)$$

- 必ず $h > 0$ となるのでパラメータ制約が不要
- v を用いているのも特徴的

高頻度データによる日次ボラティリティの推定

- 設定: 潜在的な(対数)価格過程 X

$$X(t) = X(0) + \int_0^t \sigma_x(s) d\mathbf{B}_s \quad (0 \leq t \leq 1)$$

- 目的は累積分散 (integrated volatility) を推定すること

$$\sigma_x^2 = \int_0^1 \sigma_x^2(s) ds$$

($[0,1]$ が1日を表す)

- Realized Volatility (RV)

$$RV = \sum_{j=1}^N (X_j - X_{j-1})^2$$

- (価格過程と観測価格が一致する場合) 累積分散の一致推定量
 - マーケット・マイクロストラクチャー・ノイズ (MMN) があるとき, 観測間隔を狭めると発散してしまう
 - 実用上, データを5分, 10分などに間引いて計算する
- MMNに対処する(モデルにノイズを含む)他の方法
 - Two Scale (TS) 推定量
 - Realized Kernel (RK)
 - Separating Information Maximum Likelihood (SIML) 推定量

時系列モデルの最尤推定

- 条件付き密度(尤度)

$$\begin{aligned} f_{Y_1, \dots, Y_n | Y_0}(y_1, \dots, y_n | y_0) \\ = \prod_{t=1}^n f_{Y_t | Y_{t-1}, \dots, Y_0}(y_t | y_{t-1}, \dots, y_0) \end{aligned}$$

- 通常, 対数尤度を最大化する

$$\mathcal{L}(\Theta) = \sum_{t=1}^n f_{Y_t | Y_{t-1}, \dots, Y_0}(y_t | y_{t-1}, \dots, y_0; \Theta)$$

ARCHモデルの場合

- ARCH(1)

$$y_t = u_t = \sqrt{h_t} v_t$$

$$h_t = w + \alpha u_{t-1}^2$$

- 条件付き尤度:

$$f_{Y_t|Y_{t-1}, \dots, Y_0}(y_t | y_{t-1}, \dots, y_0; \Theta) = \frac{1}{\sqrt{h_t}} g\left(\frac{y_t}{\sqrt{h_t}}\right)$$

ここで g は標準正規分布の密度関数

GARCHモデルの場合

- 実用上, GARCH(1,1)で十分な場合が多い
- GARCH(1,1)

$$y_t = u_t = \sqrt{h_t} v_t$$

$$h_t = \omega + \beta_1 h_{t-1} + \alpha_1 u_{t-1}^2$$

- 条件付き尤度:

$$f_{Y_t|Y_{t-1}, \dots, Y_0, h_0}(y_t | y_{t-1}, \dots, y_0, h_0; \Theta) = \frac{1}{\sqrt{h_t}} g\left(\frac{y_t}{\sqrt{h_t}}\right)$$

GARCHモデルの選択と診断

- 選択

- AIC や SIC を使うことが多い
- ただし、情報量規準が正当化されるのは、真のモデルを含むパラメトリックモデルに対してだけ(i.e. パラメータの追加・削減で表現可能)
- GARCH と ARCH, GJR は比較可能。EGARCH は比較不可
- それでも便宜的に IC を使う → 予測精度や診断で多面的に検討

- 診断

- 真のGARCHモデルでは、 v_t と v_t^2 は自己相関を持たない
- $\hat{v}_t = \hat{u}_t / \sqrt{\hat{h}_t}$ と $\hat{v}_t^2$ の自己相関を検定(かばん検定等)
- ARMA と同様に、修正を行う必要がある